

Lucas Rodrigues Costa

**Uso de Redes Neurais Artificiais na Predição do
Risco de Reprovação de Alunos na Educação
em Computação**

Jataí-GO

2019

Lucas Rodrigues Costa

Uso de Redes Neurais Artificiais na Predição do Risco de Reprovação de Alunos na Educação em Computação

Projeto de Pesquisa apresentado ao curso de Bacharelado em Ciências da Computação, como requisito para obtenção do grau final na disciplina de Projeto Final de Curso 1.

Universidade Federal de Goiás - Regional Jataí

Orientador: Prof. Me. Esdras Lins Bispo Jr.

Jataí-GO

2019

Lista de ilustrações

Figura 1 – Exemplo de uma “Kahoot!”	24
Figura 2 – Diagrama esquemático dos processos do projeto de pesquisa	26
Figura 3 – Diferença entre Acurácia e Precisão	28

Lista de tabelas

Tabela 1 – String de Busca	17
Tabela 2 – Características dos Trabalhos Relacionados e deste projeto de pesquisa	20
Tabela 3 – Cronograma de Atividades	30

Lista de abreviaturas e siglas

ARL - Análise de Regressão Linear

EaD - Ensino à Distância

GBL - *Games-based Learning*

IpC - Instrução pelos Colegas

IA - Inteligência Artificial

INEP - Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira

MDE - Mineração de Dados Educacionais

MEC - Ministério da Educação

PEC - Pesquisa em Educação de Computação

PI - *Peer Instruction*

RNA - Redes Neurais Artificiais

SIGCSE - *Special Interest Group on Computer Science Education*

STI - Superintendência de Tecnologia da Informação

UFG - Universidade Federal de Goiás

UFPB - Universidade Federal da Paraíba

WEI - Workshop sobre Educação em Computação

WEKA - *Waikato Environment for Knowledge Analysis*

Sumário

	Introdução	7
1	REFERENCIAL TEÓRICO	9
1.1	Educação de Computação	9
1.2	Avaliação	9
1.2.1	Avaliação diagnóstica	10
1.2.2	Avaliação somativa	11
1.2.3	Avaliação formativa	11
1.3	Inteligência Artificial	11
1.3.1	Redes Neurais Artificiais	12
1.4	Aprendizagem Baseada em jogos - <i>Games-based Learning</i>	13
1.4.1	Kahoot!	13
2	TRABALHOS RELACIONADOS	16
2.1	Levantamento Bibliográfico	16
2.1.1	Objetivo	16
2.1.2	Questões de Pesquisa	16
2.1.3	Método de pesquisa	16
2.1.3.1	Máquinas de busca utilizadas	17
2.1.3.2	Idiomas dos Artigos	17
2.1.4	Palavras-chave e <i>strings</i> de busca	17
2.1.4.1	Critérios de Seleção de Artigos e Procedimentos	18
2.1.4.2	Critérios para Inclusão de Artigos	18
2.1.4.3	Critérios para Exclusão de Artigos	18
2.1.5	Processo de triagem	18
2.2	Trabalhos Relacionados selecionados	19
2.2.1	Early Identification of Novice Programmers' Challenges in Coding using Machine Learning Techniques	19
2.2.2	Evaluating Neural Networks as a Method for Identifying Students in Need of Assistance	19
2.2.3	Predição do Desempenho do Aluno usando Sistemas de Recomendação e Acoplamento de Classificadores	19
2.2.4	Predição de desempenho de alunos do primeiro período baseado nas notas de ingresso utilizando métodos de aprendizagem de máquina	20
2.3	Tabela e descrição de características	20

3	METODOLOGIA	23
3.1	Descrição do processo metodológico	23
3.1.1	Coleta de Dados	23
3.1.1.1	Respostas ao Kahoot!	23
3.1.1.2	Resultados parciais e finais da Avaliação Somativa	24
3.1.2	Projeto e Implementação da Rede Neural	24
3.1.3	Treinamento da Rede Neural	25
3.1.4	Teste e Validação	25
3.1.5	Classificação dos alunos	25
3.1.6	Análise dos Resultados	26
3.2	Estudo de caso	26
3.2.1	Descrição do estudo de caso	26
3.2.2	Unidade de análise, Coleta de Dados e Análise dos dados	27
3.2.3	Análise dos Dados	27
3.2.3.1	Precisão e Acurácia	27
3.3	Classificação da pesquisa	28
3.3.1	Gêneros de Pesquisa	28
3.3.1.1	Quanto à natureza	28
3.3.1.2	Quanto aos objetivos	28
3.3.1.3	Quanto aos procedimentos	28
3.3.1.4	Quanto ao objeto	29
3.3.1.5	Quanto à forma de abordagem	29
4	CRONOGRAMA	30
	REFERÊNCIAS	31

Introdução

A Educação em Computação é uma área emergente e amplamente discutida pela comunidade acadêmica internacional (FINCHER; PETRE, 2005). No contexto brasileiro, o Workshop sobre Educação em Computação (WEI) tem sido um dos principais fóruns para esta discussão. O SIGCSE (*Special Interest Group on Computer Science Education Technical Symposium*) é um dos maiores eventos, em âmbito internacional, na área. Pode-se definir, como um dos objetivos principais da PEC (Pesquisa em Educação de Computação), o aperfeiçoamento do processo de ensino e aprendizagem da Computação como ciência (HOLMBOE; MCIVER; GEORGE, 2001)

Muitos alunos ingressantes em Computação apresentam dificuldades na aprendizagem, assim como em outras áreas de exatas (BLANDO, 2015). Em virtude destas dificuldades, alguns alunos não alcançam um desempenho satisfatório e reprovam em alguma disciplina. Estas reprovações podem ter, dentre outros fatores, forte influência em uma eventual evasão (PALMEIRA; SANTOS, 2015). Segundo dados do Censo da Educação Superior de 2017 (INEP, 2018), publicado pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) do Ministério da Educação (MEC), a taxa de evasão do Bacharelado em Ciência da Computação, nas universidades públicas e privadas de todo o Brasil, alcançou cerca de 60,2%, enquanto a taxa geral - média dentre todos os cursos - ficou em torno dos 26%.

Desta forma, um dos problemas na Educação em Computação é a investigação de meios mais eficazes de realizar a avaliação de aprendizagem dos alunos. Um destes interesses consiste em identificar previamente aqueles alunos que apresentam maior dificuldade na disciplina e, assim, têm maior risco de reprovação. (MARTINS; LOPES; RAABE, 2012), esses alunos que se encontram em situação de risco de reprovação são integrantes do chamado “grupo de risco”¹. Diversos autores propõem diferentes métodos para solucionar este problema. Alguns destes autores abordam modelos preditivos em relação à situação dos alunos.

Liao et al. (2016) utilizaram o modelo de **ARL (Análise de Regressão Linear)**, para fazer a análise dos dados gerados através do uso do IpC (Instrução pelos Colegas)², juntamente com o *Clicker*, pelos alunos, para tentar identificar os que estariam com tendência a baixo desempenho na disciplina, baseado nas respostas dadas nas 3 primeiras semanas de aulas. O modelo proposto alcançou, aproximadamente, 70% de acurácia na identificação de alunos com risco de reprovação, com 17% dos alunos reprovados sendo

¹ Alunos em risco: Os alunos em situação de risco são aqueles que estão propensos a não concluir um curso, seja por insuficiência de presença ou de desempenho. (SILVA et al., 2014)

² Do inglês, *Peer Instruction* (PI)

erroneamente classificados - “falsos negativos”³.

ARL também foi usada no trabalho de [Rodrigues, Medeiros e Gomes \(2013\)](#), onde investigou-se a viabilidade da aplicação de técnicas de modelagem de regressão linear para realizar inferências relativas ao desempenho de estudantes. Os resultados obtidos com o experimento confirmam que é viável, podendo afirmar que é possível estimar o desempenho de alunos baseado na quantidade de interações em ferramentas do tipo fórum de discussão.

[Porter e Zingaro \(2014\)](#) usam os dados coletados durante o uso do IpC, além dos dados de provas, para explorar as relações entre as avaliações e o desempenho em sala de aula no final do prazo. Para examinar a relação entre as notas dos alunos em avaliações diferentes, foi utilizada a **Correlação de Pearson**.

[Estey, Keuning e Coady \(2017\)](#) propuseram um método preditor que detecta, com 81% de precisão, os estudantes em situação de risco de reprovação na disciplina de programação. O estudo foi desenhado para avaliar a aprendizagem do aluno através da detecção de **mudanças no comportamento** de programação ao longo do tempo.

Uma outra proposta é o uso do **modelo PreSS** que usa fatores comparativos - como a eficiência de programação, a habilidade matemática e as horas dedicadas em exercícios - para auxiliar a identificação do alunos em risco de reprovação ([QUILLE; BERGIN, 2018](#)). Existem até ferramentas capazes de realizarem capturas de telas, que exibem código-fonte, para auxiliar na identificação das dificuldades apresentadas pelos alunos usando **aprendizado de máquina** ([AHADI, 2016](#)).

O objetivo geral deste trabalho é prever o desempenho acadêmico, na Educação de Computação, dos alunos — no contexto brasileiro — ainda no início da disciplina, identificando os que estejam no grupo de risco, possibilitando ao professor intervir. Este projeto de pesquisa tem como objetivos específicos: a implementação do projeto de Rede Neural Artificial, o treinamento e a validação desta e a análise dos resultados através de um estudo de caso no sudoeste goiano, coletando dados com o uso da plataforma "Kahoot!".

³ “Falsos negativos”: Quando os alunos são previamente classificados como não-integrantes do “Grupo de risco”, mas que, ao final da disciplina, acabaram reprovando

1 Referencial Teórico

Para melhor compreensão do texto, é importante estabelecer as definições de alguns conceitos que serão adotados neste projeto de pesquisa.

1.1 Educação de Computação

Educação de computação é o resultado da fusão de, a princípio — Outras também estão envolvidas, como: Psicologia, engenharias, tecnologia, entre outras —, duas disciplinas: Educação e Computação.

Educação é um processo que visa ao desenvolvimento físico, intelectual e moral do ser humano, através da aplicação de métodos próprios, com intuito de assegurar-lhe a integração social e formal da cidadania ([WEISZFLOG, 1999](#)). Ciência da Computação é o estudo sistemático de algoritmo e estrutura de dados, i.e., o estudo do seu formalismo, desenvolvimento e aplicações. ([GIBBS; TUCKER, 1986](#))

O objetivo principal da pesquisa em Educação de Computação é o aperfeiçoamento do processo de ensino e aprendizagem da Computação como ciência. ([HOLMBOE; MCIVER; GEORGE, 2001](#))

[Fincher e Petre \(2005\)](#) identificam dez grandes áreas de interesse para pesquisadores em Educação de Computação. As dez áreas são: a compreensão do aluno, sistemas de animação/visualização/simulação, métodos de ensino, avaliação, tecnologia educacional, a transferência de prática profissional em sala de aula, a incorporação de um novo desenvolvimento e novas tecnologias na sala de aula, transferindo para o ensino à distância (“EaD” ou “*e-learning*”), recrutamento e retenção de alunos, a construção da disciplina em à distância (“EaD” ou “*e-learning*”), e finalmente, a construção da disciplina em si.

1.2 Avaliação

A avaliação é uma área ampla, que pode ser dividida em termos de tipos de avaliação, validade da avaliação e classificação automatizada. ([FINCHER; PETRE, 2005](#))

Segundo [Libâneo \(1994\)](#), avaliação pode ser definida como um componente do processo de ensino que visa, através da verificação e qualificação dos resultados obtidos, determinar a correspondência deste com os objetivos propostos e, daí, orientar a tomada de decisões em relação às atividades didáticas subsequentes.

Outra definição foi dada por [Domingos, Neves e Galhardo \(1981\)](#), onde a avaliação pode ser entendida como um processo sistemático de determinar a extensão em que

os objetivos educacionais foram alcançados pelos alunos. O que se avalia são as metas de aprendizagem definidas e para as quais se caminhou durante todo um processo de aprendizagem levado a cabo pelo professor e pelo aluno

A avaliação da aprendizagem possibilita a tomada de decisão e a melhoria da qualidade de ensino, informando as ações em desenvolvimento e a necessidade de regulações constantes. (KRAEMER, 2005)

Para Datrino, Datrino e Meireles (2015), avaliação vista como uma etapa da aprendizagem passa a ser utilizada como um processo, isto é, na formação e construção do conhecimento levando a uma reflexão sobre as ações, gestos e pensamentos. Os processos formativos precisam ser avaliados em sua forma, efeito, método e evolução dos educandos.

Os métodos avaliativos são de suma importância no processo de ensino-aprendizagem. Diversos autores demonstram os benefícios resultantes de uma boa avaliação durante as aprendizagens e conhecimentos adquiridos pelos discentes. Porém, é preciso que sejam escolhidos e aplicados no cotidiano do aluno de forma a conduzi-lo à aprendizagem, obtendo assim resultados satisfatórios a partir de sua avaliação e evitando análises errôneas e estresse por parte dos educadores e educandos. (SILVA et al., 2014)

Segundo Libâneo (1994), o entendimento correto da avaliação consiste em considerar a relação mútua entre os aspectos quantitativos e qualitativos. A avaliação não pode ser vista apenas como “medida”, mas também não pode ser baseada na subjetividade de professores e alunos.

Bloom et al. (1983) classificaram a avaliação em três tipos, sendo eles: avaliação diagnóstica; avaliação formativa e avaliação somativa.

1.2.1 Avaliação diagnóstica

Conhecer o aluno, seus gostos, seus hábitos e suas preferências, é o princípio base da avaliação diagnóstica. Dessa forma, assegura-se que o aluno esteja na turma correta e que o curso encontre-se no nível adequado a ele. Nesta avaliação busca-se conhecer ideias e conhecimentos prévios do aluno (MASETTO, 1994).

Para Bloom et al. (1983), avaliação diagnóstica visa verificar a existência, ou ausência, de habilidades e conhecimentos pré-estabelecidos, esta é uma ação que inicia o processo avaliativo e verifica se os alunos dominam os pré-requisitos necessários para novas aprendizagens.

Segundo Haydt (2007), a partir de uma avaliação diagnóstica o docente constata se os seus alunos estão ou não preparados, se possuem domínio de pré-requisitos para adquirir novos conhecimentos. Portanto, a avaliação diagnóstica permite que o professor conheça seu aluno por um mecanismo de triagem e calibração

1.2.2 Avaliação somativa

Avaliação somativa é uma decisão que leva em conta a soma de um ou mais resultados e pode ser baseada numa só prova final (OLIVEIRA; CHADWICK, 2004).

De acordo com Haydt (2007), esse tipo de avaliação tem por princípio classificar os resultados de aprendizagem alcançados pelos alunos de acordo com os níveis de aproveitamento estabelecidos, adotando assim uma função classificatória.

A avaliação somativa pretende ajuizar o progresso realizado pelo aluno, no final de uma unidade de aprendizagem, no sentido de aferir resultados já recolhidos por avaliações do tipo formativo e obter indicadores que permitam aperfeiçoar o processo de ensino (KRAEMER, 2005).

1.2.3 Avaliação formativa

A idéia de avaliação formativa é sistematizar o funcionamento, levando o professor a observar mais metodicamente os alunos, a compreender melhor seus funcionamentos, de modo a ajustar de maneira mais sistemática e individualizada suas intervenções pedagógicas e as situações didáticas que propõe, tudo isso na expectativa de otimizar a aprendizagem. A avaliação formativa está portanto centrada essencialmente, direta e imediatamente, sobre a gestão das aprendizagens dos alunos (pelo professor e pelos interessados). Essa concepção se situa abertamente na perspectiva de uma regulação intencional, cuja intenção seria determinar ao mesmo tempo o caminho já percorrido por cada um e aquele que resta a percorrer com vistas a intervir para otimizar os processos de aprendizagem em curso. (PERRENOUD, 1999)

A avaliação formativa responde a uma concepção do ensino que considera que aprender é um longo processo, por meio do qual o aluno vai reestruturando seu conhecimento a partir das atividades que executa. Esse tipo de avaliação tem como finalidade fundamental a função ajustadora do processo de ensino-aprendizagem para possibilitar que os meios de formação respondam as características dos alunos. Pretende-se detectar os pontos fracos da aprendizagem, mais do que determinar quais os resultados obtidos com essa aprendizagem. (JORBA; SANMARTI, 2003)

1.3 Inteligência Artificial

A IA (Inteligência Artificial) é uma das ciências mais recentes. O trabalho começou logo após Segunda Guerra Mundial, tendo este nome cunhado em 1956. (RUSSELL; NORVIG, 2004)

Segundo Bellman (1978), a IA é a automatização de atividades que podem ser associadas ao pensamento humano, atividades como a tomada de decisões, a resolução de

problemas, o aprendizado, entre outros.

Várias disciplinas contribuíram com ideias, pontos de vista e técnicas para a IA. Dentre elas estão: Filosofia, Matemática, Economia, Neurociência, Psicologia, Engenharia de Computadores, Teoria de Controle e Cibernética, Linguística, entre outras. (RUSSELL; NORVIG, 2004)

A IA abrange uma enorme variedade de subcampos, desde áreas de uso geral, como aprendizado e percepção, até tarefas específicas como diagnóstico de doenças, por exemplo. A IA sistematiza e automatiza tarefas intelectuais e, portanto, é potencialmente relevante para qualquer esfera da atividade intelectual humana. (RUSSELL; NORVIG, 2004)

De acordo com Sage (1990), o objetivo da IA é o desenvolvimento de paradigmas ou algoritmos que requeiram máquinas para realizar tarefas cognitivas, para as quais os humanos são atualmente melhores. Um sistema de IA tem três componentes fundamentais: representação, raciocínio e aprendizagem.

Aprendizado de Máquina é uma área da IA cujo objetivo é o desenvolvimento de técnicas computacionais sobre o aprendizado bem como a construção de sistemas capazes de adquirir conhecimento de forma automática. Um sistema de aprendizado é um programa de computador que toma decisões baseado em experiências acumuladas através da solução bem sucedida de problemas anteriores. Os diversos sistemas de aprendizado de máquina possuem características particulares e comuns que possibilitam sua classificação quanto à linguagem de descrição, modo, paradigma e forma de aprendizado utilizado (MONARD; BARANAUSKAS, 2003). Uma das técnicas de aprendizado de máquina são as Redes Neurais Artificiais.

1.3.1 Redes Neurais Artificiais

Um neurônio é uma célula no cérebro cuja a principal função é coletar, processar e disseminar sinais elétricos. Uma parte do trabalho inicial da IA teve como objetivo criar **Redes Neurais Artificiais** (RNA). Estas são funções não-lineares complexas com muitos parâmetros. (RUSSELL; NORVIG, 2004)

Segundo Haykin (2001), uma rede neural é um processador maciçamente paralelamente distribuído constituído de unidades de processamento simples, que têm a propensão natural para armazenar conhecimento experimental e torná-lo disponível para o uso. Ela se assemelha ao cérebro em dois aspectos: Conhecimento adquirido pela rede, através de um processo de aprendizagem. Forças de conexão entre neurônios, conhecidos como pesos sinápticos, usados para armazenar o conhecimento adquirido.

Haykin (2001) descreveu ainda que a arquitetura de uma rede neural restringe o tipo de problema no qual a rede poderá ser utilizada, e é definida pelo número de camadas (camada única ou múltiplas camadas), pelo número de nós em cada camada, pelo tipo de

conexão entre os nós (*feedforward* ou *feedback*) e por sua topologia.

1.4 Aprendizagem Baseada em jogos - *Games-based Learning*

Aprendizagem Baseada em jogos, ou GBL (pela sigla em inglês de *Games-based Learning*), foi definida por alguns autores. Segundo [Tang, Hanneghan e Rhalibi \(2009\)](#), GBL faz referência a uma abordagem de aprendizagem inovadora derivada do uso de jogos de computador que tem valor educacional ou diferentes tipos de aplicação de software que usam jogos computacionais para ensino e educação. GBL's têm como finalidade o apoio à aprendizagem, a avaliação e análise de alunos e melhoria do ensino.

A aprendizagem baseada em jogos surge como uma alternativa de ensino que se adapta às características da pedagogia moderna na qual o estudante é um ator ativo ([MONSALVE, 2014](#)).

Com a aprendizagem baseada em jogos, se pretende equilibrar entretenimento e difusão do conhecimento, motivando os estudantes a aprender enquanto jogam ([MONSALVE; WERNECK; LEITE, 2011](#)).

[Souza et al. \(2017\)](#) definiram *GBL* como o ato de aplicar jogos com o propósito de aprender habilidades e conceitos específicos, geralmente nomeado como “jogos sérios” (jogos com fins), entretenimento educativo¹ ou jogos educativos.

[Wangenheim e Shull \(2009\)](#) definiram GBL como uma abordagem lida com aplicativos de jogos que definiram resultados de aprendizagem.

Algumas plataformas de GBL foram utilizadas por autores no processo de ensino-aprendizagem. Um destes foi o de [Lot e Salleh \(2016\)](#), onde abordaram o uso de GBL como avaliação formativa, com a plataforma **Zoondle**. Outras plataformas de GBL usadas foram a **EducaCross**, no trabalho de [Reis et al. \(2016\)](#), a **Timemesh**, no trabalho de [baptista2013timemesh](#) e, provavelmente o mais popular, **Kahoot!**, que será usado neste projeto de pesquisa.

1.4.1 Kahoot!

Kahoot! é uma plataforma de aprendizado baseada em jogos, usada como tecnologia educacional em escolas, universidades e outras instituições de ensino. Kahoot! foi fundada por Johan Brand, Jamie Brooker e MortenVersvik em um projeto conjunto com a Universidade Norueguesa de tecnologia e ciência ([ABOUT..., 2019](#))

Seus jogos de aprendizado, “Kahoots”, são *quizzes*, perguntas de múltipla escolha, que permitem a criação de usuários e podem ser acessados por meio de um navegador da

¹ Do termo, em inglês, “*Edutainment*”, que seria a união de educação (*Education*) e entretenimento (*entertainment*)

Web, telefone ou pelo aplicativo.

Kahoot! foi projetado para a aprendizagem social, com os alunos reunidos em torno de uma tela comum, como um quadro interativo, projetor ou um monitor de computador. O site também pode ser usado por meio de ferramentas de compartilhamento de tela, como Skype ou Google hangouts. Kahoot! pode ser usado para revisar o conhecimento dos alunos, para avaliação formativa (LIPP, 2015), ou como uma pausa com as atividades tradicionais em sala de aula.

A jogabilidade é simples; todos os jogadores se conectam usando um PIN de jogo gerado na tela comum e usam um dispositivo para responder a perguntas criadas pelo professor. As questões podem ter pontuações atribuídas, em relação ao acerto e ao tempo para resposta. Os pontos aparecem no placar depois de cada pergunta.

Alguns trabalhos relataram os resultados encontrados ao utilizar o Kahoot! no processo de ensino. Um destes foi realizado por Diniz e Ferreira (2018), que usou a ferramenta com alguns alunos de Ciência da Computação, obtendo resultados satisfatórios quanto a aceitação da ferramenta no contexto educacional.

Considerando que alguns fatores sociais e geográficos podem afetar a aplicação e a eficiência do uso desta ferramenta, faz-se necessário avaliá-la no contexto dos estudantes brasileiros.

No trabalho de Petri et al. (2016), o Kahoot! foi utilizado como um *quiz* com perguntas sobre Gerenciamento de Projetos, disponibilizado para alunos dos cursos de Sistemas de Informação e Ciência da Computação como forma de revisão de conteúdo. Os autores identificaram *feedbacks* positivos nos resultados encontrados. Afirmaram também que o jogo educacional cumpriu com o seu objetivo de aprendizagem por proporcionar a revisão de conhecimentos de forma divertida e motivadora.

Para os autores Abidin e Zaman (2017), a utilização do Kahoot! foi uma estratégia de motivação para os alunos de uma faculdade de Engenharia Elétrica ao cursarem uma disciplina de programação de computadores. O conteúdo apresentado no *game* era relacionado a disciplina em questão e o objetivo era possibilitar aos alunos uma experiência atrativa para a aprendizagem, pois muitos deles perdiam o entusiasmo ao estudarem programação de computadores. O resultado mostrou que a grande maioria dos alunos conseguiu melhorar sua compreensão sobre a disciplina e também se mostraram mais engajados e motivados ao final do experimento.

Outro trabalho similar foi o realizado por Correia e Santos (2017), que apresenta as opiniões de alunos de um programa de formação de professores (licenciatura e mestrado) sobre as vantagens e desvantagens da utilização do Kahoot! em sala de aula. Como vantagens percebidas estão a correção automática das questões e o *feedback* em tempo real para os alunos e professores. Como desvantagens, foram identificados os seguintes fatores:

numero limitado de caracteres tanto para o enunciado das questões quanto para as opções de respostas, além do tempo limitado de resposta.

Kahoot, mantém as mesmas utilidades que outros métodos de resposta rápida; especialmente os *clickers*, mas sem todos os problemas técnicos e logísticos destes. (HOLGUÍN et al., 2014)

2 Trabalhos Relacionados

No decorrer dessa pesquisa foram encontrados alguns trabalhos que propõem métodos para a predição de desempenho acadêmico. Nesta seção, serão apresentados do levantamento bibliográfico feito para encontrar esses trabalhos, os trabalhos correlatos que estão fortemente ligados com este projeto de pesquisa, seguido de breve resumo do que cada autor propôs e obteve como resultado, e uma tabela apresentando as características de cada um dos trabalhos.

2.1 Levantamento Bibliográfico

2.1.1 Objetivo

O objetivo deste levantamento bibliográfico é fazer uma revisão, seleção e organização dos artigos que possam identificar os alunos em situação de risco, analisando os métodos propostos.

2.1.2 Questões de Pesquisa

Para nortear esta levantamento, foram definidas questões que elenquem pontos relevantes a serem estudados.

- **Questão 1:** Quais métodos foram propostos para identificar alunos com risco de reprovação em disciplinas?
- **Questão 2:** Quais os graus de precisão e acurácia alcançados ao utilizar-se destes métodos?
- **Questão 3:** Redes Neurais Artificiais foram utilizadas? Se sim, são assertivas na predição de alunos em situação de risco?
- **Questão 4:** Quais são as vantagens de se utilizar Redes Neurais Artificiais para tal?

2.1.3 Método de pesquisa

Nesta seção serão descritos alguns elementos utilizados para o levantamento bibliográfico, de acordo com [Kitchenham \(2004\)](#). São estes: o escopo da pesquisa, o idioma considerado, os termos utilizados, a *string* de busca e os critérios de seleção de artigos.

2.1.3.1 Máquinas de busca utilizadas

Para este levantamento bibliográfico, foram escolhidos três das principais máquinas de buscas disponíveis atualmente. Aplicou-se as *Strings* de buscas que serão mais a frente, a fim de identificar potenciais trabalhos correlatos ao tema deste. As máquinas de busca utilizadas para a pesquisa foram:

- ACM Digital Library
- Google Scholar
- IEEE Xplore

2.1.3.2 Idiomas dos Artigos

Por se tratarem da língua oficial brasileira e uma das línguas mais faladas, respectivamente, Português e Inglês foram os idiomas escolhido para a pesquisa dos artigos.

2.1.4 Palavras-chave e *strings* de busca

As palavras-chave que compõem a busca são (em português e inglês, respectivamente): Educação de Computação, Ensino de Computação, Introdução a Computação, Avaliação, Estimativa, Previsão, Inteligência Artificial, Mineração de Dados, Aprendizado em Profundidade, Redes Neurais Artificiais, RNA, *Computer Education*, *CS1*, *Assessment*, *Prediction*, *Artificial Intelligence*, *Data Mining*, *Clicker*, *Deep Learning*, *Artificial Neural Network*, *ANN*.

A [Tabela 1](#) mostra as *strings* de busca foram geradas a partir da combinação das palavras chave, dividida pelos idiomas estabelecidos.

Tabela 1 – String de Busca

Português	(“Educação de computação” OR “ensino de computação” AND “Introdução a Computação” OR “Avaliação”) AND (“estimativa” OR “previsão” AND “Inteligência Artificial” OR “mineração de dados” OR “Aprendizado em Profundidade” OR “Redes Neurais Artificiais” OR “RNA”)
Inglês	(“ <i>Computer Education</i> ” AND “ <i>cs1</i> ” OR “ <i>assessment</i> ”) AND (“ <i>prediction</i> ” OR “ <i>data mining</i> ” OR “ <i>artificial intelligence</i> ” OR “ <i>deep learning</i> ” OR “ <i>Artificial neural network</i> ” OR “ <i>ANN</i> ”))

2.1.4.1 Critérios de Seleção de Artigos e Procedimentos

[Kitchenham \(2004\)](#) diz que devem ser seguidos critérios de inclusão e exclusão para os artigos que são retornados pela *string* de busca. Sendo assim, foram definidos os seguintes critérios:

2.1.4.2 Critérios para Inclusão de Artigos

1. Pesquisas as quais tratam sobre utilização de métodos para identificação de alunos em situação de risco de reprovação;
2. Pesquisas as quais tratam sobre inteligência artificial no contexto educação de computação e no processo de ensino-aprendizagem;
3. Pesquisas as quais tratam sobre previsão do desempenho acadêmico com uso de aprendizado de máquina.

2.1.4.3 Critérios para Exclusão de Artigos

1. Não apresentar necessidade de identificar os alunos em situação de riscos;
2. Não satisfaçam a nenhum critério de inclusão;
3. Não apresentar a forma utilizada para coletar dados;
4. Não apresentou os métodos utilizados para analisar os dados obtidos;
5. Não foi possível ter acesso a pesquisa completa;
6. A pesquisa não está disponível na *web*;
7. A pesquisa é publicada apenas como resumo;
8. Trabalhos que são réplicas ou continuações/evoluções de projetos de pesquisas iniciais, incluindo o trabalho mais completo (Geralmente, o mais recente);
9. Ter sido publicado em período anterior a 2013.

2.1.5 Processo de triagem

Foi realizada uma primeira triagem, que consistiu na leitura do título, do resumo (*abstract*) e das palavras-chave (*keywords*) dos trabalhos previamente recuperados, aplicando os critérios de inclusão e exclusão e as *Strings* de busca. A etapa seguinte teve como objetivo realizar a leitura completa e minuciosa dos artigos selecionados na primeira

fase. Desta forma, a segunda fase do processo de triagem possibilita fazer uma análise mais apurada dos estudos, identificando e extraindo dados de acordo com os critérios de inclusão e exclusão descritos anteriormente.

2.2 Trabalhos Relacionados selecionados

Após os processos de seleção e triagem, quatro artigos foram considerados fortemente relacionados a este projeto de pesquisa. A seguir, será feito um breve resumo do que foi proposto em cada um deles. Após, será apresentada a ?? com um comparativo de características elencadas para que se faça um paralelo do que já foi proposto por outros autores e o que é alvitado por este projeto. Por fim, uma breve discussão, destrinchando cada elemento característico dos trabalhos correlatos.

2.2.1 Early Identification of Novice Programmers' Challenges in Coding using Machine Learning Techniques

Em sua tese de Doutorado, [Ahadi \(2016\)](#) usou Mineração de Dados Educacionais e técnicas de *Machine Learning* para analisar dados coletados de programadores novatos no primeiro semestre, durante a realização de exercícios semanais nos laboratórios.

2.2.2 Evaluating Neural Networks as a Method for Identifying Students in Need of Assistance

O trabalho de [Castro-Wunsch, Ahadi e Petersen \(2017\)](#) teve o objetivo de explorar a eficácia das Redes Neurais na identificação precoce de alunos que necessitavam de auxílio. Eles usaram trechos de códigos através de capturas instantânea de tela - *Snapshots* e, assim, puderam aplicar a técnica de RNA para analisar a solução usada pelos alunos para os problemas propostos.

2.2.3 Predição do Desempenho do Aluno usando Sistemas de Recomendação e Acoplamento de Classificadores

[Gotardo, Cereda e Junior \(2013\)](#), em um de seus trabalhos, apresenta uma abordagem que usa algoritmos de aprendizado de máquina acoplados para integrar as diferentes técnicas para explorar um conjunto de dados educacionais oferecendo recomendação sobre o desempenho do aluno.

2.2.4 Predição de desempenho de alunos do primeiro período baseado nas notas de ingresso utilizando métodos de aprendizagem de máquina

Outro trabalho com objetivo de identificar os estudantes que necessitam de apoio didático foi o de [Brito et al. \(2014\)](#), onde nas disciplinas do primeiro período do curso de Ciência da Computação da Universidade Federal da Paraíba (UFPB) foi avaliada a relação entre as notas de ingresso do aluno e o seu desempenho no primeiro período do curso. No trabalho, foram utilizados algoritmos de aprendizado de máquina implementados pela ferramenta WEKA (*Waikato Environment for Knowledge Analysis*) - dentre eles, Redes Neurais, Árvore de Decisão e Redes Bayesianas - na análise dos dados. Os resultados deram indícios de que essa relação existe.

2.3 Tabela e descrição de características

Tabela 2 – Características dos Trabalhos Relacionados e deste projeto de pesquisa

Artigos/Características	C1	C2	C3	C4
Ahadi (2016)		X		
Castro-Wunsch, Ahadi e Petersen (2017)		X		
Gotardo, Cereda e Junior (2013)				X
Brito et al. (2014)		X		X
Esse trabalho	X	X	X	X

Critério 1 (C1) - A ferramenta de Coletas de Dados usada era alguma Plataforma Baseada em Jogos?

- O trabalho de [??](#)) utilizou Mineiração de Dados Educacionais e Snapshots de códigos-fonte. [Castro-Wunsch, Ahadi e Petersen \(2017\)](#) também usou Snapshots. *Snapshots* de códigos-fonte gerados são feitos através de uma ferramenta que captura trechos dos códigos-fonte produzido pelos alunos.
- [Gotardo, Cereda e Junior \(2013\)](#) abordou o uso da interação dos alunos no ambiente *Moodle*, onde se contabilizava o número de interações. e quais eram, feitas pelos alunos no ambiente. *Moodle* é o acrônimo de “*Modular Object-Oriented Dynamic Learning Environment*”, um software livre, de apoio à aprendizagem, executado num ambiente virtual.
- E outra fonte de dados são as notas dos alunos. No trabalho de [Brito et al. \(2014\)](#), as notas — fornecidas pela STI - Superintendência de Tecnologia da Informação da UFPB - Universidade Federal da Paraíba — de ingresso, sendo atributos considerados:

Média Geral no vestibular, Média de Matemática e a média em Física obtidos no processo seletivo para a entrada na UFPB, e as notas obtidas nas disciplinas do primeiro período do curso foram utilizadas para se analisar. Neste trabalho, duas das fontes de dados são notas finais/parciais do processo de avaliação somativa da disciplina do estudo de caso.

- Um dos diferenciais deste projeto de pesquisa é a utilização da Plataforma de Aprendizado Baseado em jogos, “Kahoot!”, descrita em: [1.4.1](#). O Kahoot! será a ferramenta utilizada na coleta de duas das quatro fontes de dados desse projeto.

Critério 2 (C2) - Rede Neural Artificial foi especificada como técnica de Análise de Dados no trabalho?

Os trabalhos selecionados utilizaram técnicas de Machine Learning para a análise dos dados. Em alguns a técnica utilizada foi especificada, em outros não.

- Em seu trabalho, [Ahadi \(2016\)](#) utilizou técnicas de *Machine Learning*, mas não as especificaram, e comparou os resultados encontrados entre elas. ou uso de ferramentas que implementam e/ou acoplam técnicas de *Machine Learning* para análise dos dados. [Gotardo, Cereda e Junior \(2013\)](#) utilizou uma ferramenta que faz o aprendizado baseado em acoplamento de algoritmos classificadores, não explicitando se Redes Neurais estava entre eles.
- [Brito et al. \(2014\)](#) e [Castro-Wunsch, Ahadi e Petersen \(2017\)](#) utilizaram Redes Neurais Artificiais em seus trabalhos. Eles utilizaram a ferramenta WEKA que, dentre outras, implementa a técnica de RNA. Este trabalho tem como um dos objetivos específicos, implementar uma Rede Neural, projetando uma arquitetura que atenda as necessidades encontradas. RNA foi descrita em [subseção 1.3.1](#).

Critério 3 (C3) - A disciplina onde os trabalhos fizeram a análise de dados eram disciplinas do núcleo específico do curso de Ciência da Computação

O curso de Ciência da Computação é extremamente amplo, tendo um vasto leque de opções de áreas de atuação e interesse. O curso pode ser dividido em disciplinas introdutórias e de base, chamadas de núcleo básico da grade curricular, e disciplinas que abrangem especificidades de cada área, chamadas de núcleo específico.

- O trabalho de [Castro-Wunsch, Ahadi e Petersen \(2017\)](#), trabalha com disciplinas do núcleo básico, sendo elas Introdução a Programação⁴ em *Python* e em Java. [Ahadi \(2016\)](#) também usou dados oriundos de uma disciplina de introdução a programação.

⁴ Do inglês, *CS1 - Computer Science 1*, que são disciplinas que fazem uma introdução do conteúdo básico de programação

- [Gotardo, Cereda e Junior \(2013\)](#) não especifica as disciplinas em que os dados serão coletados.
- No trabalho de [Brito et al. \(2014\)](#), além das notas obtidas no processo seletivo, como já descrito anteriormente, as notas obtidas nas matérias do núcleo básico do curso foram considerados na disciplina. As disciplinas em questão foram: Cálculo Diferencial e Integral 1, Física Aplicada à Computação 1, Cálculo Vetorial e Geometria Analítica, disciplinas ofertadas no primeiro período do curso de Ciência da Computação da UFPB.
- Já este trabalho se propõe a analisar dados coletados em uma disciplina do núcleo específico do curso, Interface Humano-Computador, com dados provenientes das turmas de 2018.2 e 2019.2, na UFG.

Critério 4 (C4) - Os trabalhos foram realizados no Contexto Brasileiro?

O contexto onde o trabalho foi realizado pode influenciar no resultado final por diversos fatores. É interessante aplicar para verificar-se a aplicabilidade em contexto Brasileiro.

- O trabalho de [Castro-Wunsch, Ahadi e Petersen \(2017\)](#) foi realizado em uma Universidade Norte-Americana de Pesquisa Intensiva que foi omitida, Esse trabalho foi realizado também em outra Universidade.
- A Universidade supracitada foi uma Universidade Europeia de Pesquisa Intensiva. Essa Universidade já proveu dados para outro trabalho de Ahadi.
- [Ahadi \(2016\)](#) que teve um de seus trabalhos escolhidos como fortemente relacionados com esse, realizou o estudo em duas Universidades. Uma foi a University of Helsinki, Finland, na Europa.
- A outra Universidade, onde o trabalho anterior foi aplicado, é a University of Technology, Sydney, Austrália.
- No contexto brasileiro, dois trabalhos foram identificados como fortemente correlatos a proposto deste.
 - [Brito et al. \(2014\)](#) realizou seu trabalho na Universidade Federal da Paraíba.
 - Já no trabalho de [Gotardo, Cereda e Junior \(2013\)](#), foi realizado o estudo em uma Universidade à Distância que foi omitida
 - E este trabalho, onde será realizado um estudo de caso na Universidade Federal de Goiás, situada no sudoeste goiano.

3 Metodologia

Na [seção 3.1](#) será descrito os passos que serão realizados, os processos metodológicos adotados na pesquisa e como ocorrerá cada etapa do projeto. Já na [seção 3.2](#) serão abordados os elementos essenciais de um estudo de caso e a descrição de como será realizado o estudo de caso deste projeto de pesquisa. E, por fim, na [seção 3.3](#) será realizado a classificação do projeto de pesquisa quanto aos gêneros identificados.

3.1 Descrição do processo metodológico

Nesta seção serão descritos os processos que serão realizados para se alcançar os objetivos geral e específicos estabelecidos.

3.1.1 Coleta de Dados

Para este projeto de pesquisa, serão adotadas 4 fontes de dados. Esses dados coletados darão suporte para proposições que serão feitas para solucionar o problema. As quatro fontes de dados que serão usadas são: as respostas do Kahoot! de 2018.2, os resultados finais do processo de avaliação somativa de 2018.2, as respostas do Kahoot! de 2019.2 e os resultados parciais de 2019.2, as quatro na disciplina de Interface Humano-Computador.

3.1.1.1 Respostas ao Kahoot!

O Kahoot! é uma plataforma de GBL e foi descrita melhor na [subseção 1.4.1](#). Na disciplina de Interface Humano-Computador, ela foi utilizada em 2018.2 e será utilizada em 2019.2 novamente. O Kahoot! tem um caráter fortemente formativo, sendo aplicado ao final de cada aula, com questões elaboradas pelo professor que abordem assuntos que foram ministrados na aula.

As perguntas são de múltipla-escolha, tendo entre duas e cinco alternativas de respostas para o aluno. Neste projeto de pesquisa, serão usados os dados provenientes de respostas dadas pelos alunos aos questionários aplicados nas turmas de 2018.2 e 2019.2 da disciplina de Interface Humano-Computador da UFG, localizada em Jataí, sudoeste goiano.

Na [Figura 1](#) é apresentado um *Screenshot* de um exemplo de pergunta no Kahoot!

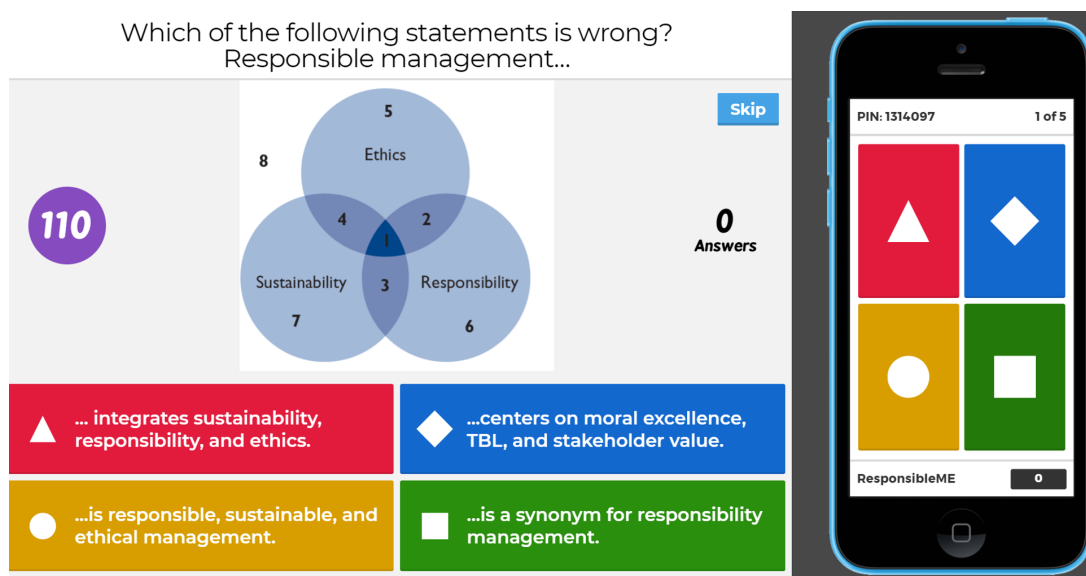


Figura 1 – Exemplo de uma “Kahoot!”

3.1.1.2 Resultados parciais e finais da Avaliação Somativa

O processo de Avaliação Somativa foi descrito na [subseção 1.2.2](#). O Kahoot! além de caráter formativo, ele também tem, ainda que pouco, caráter somativo. Além disso, serão utilizadas os resultados parciais e finais da disciplina de IHC para a análise dos resultados do projeto.

Na turma de 2018.2, serão usados os resultados finais da Avaliação Somativa. A disciplina já se encerrou, tendo que apenas a posse desses dados para realizar a análise. Já na turma de 2019.2, os resultados da Avaliação Somativa que serão usados são os parciais, consistindo de 2/3 da disciplina já tendo sido realizadas. O motivo desse ocorrido se dá em função do período de obtenção e análise destes, visto que para se ter os resultados finais não haveria tempo hábil para realizar a análise completa destes, tendo assim uma perda. Acredita-se que, com este porção de dados, será suficiente para se ter resultados significativos e, assim, apresentar uma contribuição relevante para a comunidade científica.

3.1.2 Projeto e Implementação da Rede Neural

O projeto da Rede consiste em pegar um conjunto de dados de entrada, aplicar essa entrada em neurônios, onde esses reajustarão os pesos destas. A rede produz uma saída com a “previsão” da rede, aprovado ou reprovado — sendo depois indicado o grau, fortemente ou provavelmente. O conjunto de entrada da Rede é composto por um vetor onde estará as respostas dadas pelos alunos.

A Rede Neural Artificial será a técnica de aprendizagem de máquina usada por este projeto de pesquisa. A descrição desta foi feita na [subseção 1.3.1](#). Para isso, será projetada uma Rede Neural Artificial, adotando uma arquitetura de rede específica.

A implementação da rede será feita na linguagem de programação *Python*, que é uma linguagem interpretada, de *script*, imperativa, orientada a objetos, funcional, de tipagem dinâmica e forte. Python é uma das opções mais comuns, quando se trata de Inteligência Artificial, talvez a que tenha mais biblioteca para Aprendizado de Máquina e Análise de Dados.

Uma destas bibliotecas é a TensorFlow, que é de código-aberto. É com ela que será criada e treinada a Rede Neural proposta por esta pesquisa. Essa biblioteca consiste em detectar e decifrar padrões e correlações, análogo à maneira com que o seres-humanos aprendem e raciocinam.

3.1.3 Treinamento da Rede Neural

Como dito, o treinamento da Rede Neural será feito com a biblioteca TensorFlow na linguagem Python. Os dados usados para esse treinamento da rede seram os dados de 2018.2 e 2019.2 de IHC. O projeto consiste em dividir as resposta pelo período em que elas foram aplicadas, sendo estes em 3 subdivisões.

A primeira rede será a rede com as entradas de dados dos primeiros 15 dias de aula, sendo estas entradas as respostas dadas nesse período às questões do Kahoot!, a segunda divisão será feita da mesma forma, porém as entradas serão as respostas dos primeiros 30 dias de aula. E, por fim, a última rede consistirá das respostas dadas nos primeiros 60 dias de aula.

Nas figuras **Colocar figuras**, está ilustrado como serão feitas as redes, os conjuntos de entrada

3.1.4 Teste e Validação

O teste e a validação serão feitos nas semanas subsequentes às estabelecidas para o treinamento, com as redes já com os “neurônios” com seu respectivo peso, feito através do processo de treino da rede. Ao fazer o teste e a validação, os alunos serão classificados em 4 grupos, que apresentará o grau de risco e a situação dos alunos frente às previsões realizadas pela rede.

3.1.5 Classificação dos alunos

Após a análise ser feita pela Rede, o conjunto de saída apontará o aluno para que este integre um entre quatro grupos que serão estabelecidos. Os grupos seriam definidos como: Fortemente Reprovados (FR), Provavelmente Reprovados (PR), Provavelmente Aprovados (PA) e Fortemente Aprovados (FA). Esses níveis dizem respeito ao quão o aluno está propenso à reprovar. Pensando em um plano cartesiano, seria como se no eixo das abcissas fosse posto esses níveis classificatórios. Nessa analogia, quanto mais à esquerda o

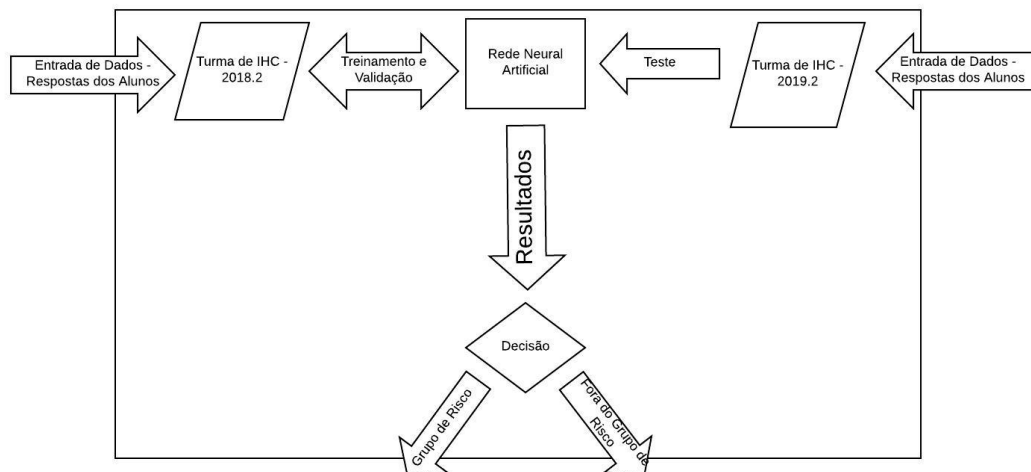


Figura 2 – Diagrama esquemático dos processos do projeto de pesquisa

aluno fosse classificado, maior seria a chance do aluno ser reprovado na disciplina, quanto mais à direita o aluno fosse classificado, maior seria a chance desse aluno ser aprovado.

A questão que aparece ao se fazer essa classificação é a seguinte: “Um aluno não pode ser classificado de forma errada?”. Sim, ele pode, e isso é descrito por quatro conceitos importantes de serem definidos neste projeto de pesquisa, que são: Falsos-positivos, Falsos-negativos, Verdadeiros-negativos, Verdadeiros-positivos.

3.1.6 Análise dos Resultados

3.2 Estudo de caso

Um estudo de caso é uma investigação empírica que investiga um fenômeno contemporâneo dentro de seu contexto da vida real, especialmente quando os limites entre o fenômeno e o contexto não estão claramente definidos (YIN, 2001). Esta investigação enfrenta uma situação tecnicamente única em que haverá muito mais variáveis de interesse do que fonte de dados, e, como resultado, (1) baseia-se em fontes de evidências, com os dados precisando assimilar-se a trabalhos correlatos, e, como outro resultado, (2) beneficia-se do desenvolvimento prévio de proposições teóricas para conduzir a coleta e análise de dados.

3.2.1 Descrição do estudo de caso

Este é um estudo de caso único holístico, utilizando uma estratégia exploratória. A justificativa deste estudo reside no caso revelador que é o uso de RNA na predição de desempenho acadêmico dos alunos em Educação de Computação no Brasil. Os estudos do

levantamento bibliográfico concentram-se principalmente em países da América do Norte, Europa e Oceania, como descrito no [Capítulo 2](#). Segundo [YIN \(2001\)](#), um estudo de caso contém, em especial, cinco componentes importantes de um projeto de pesquisa que serão descritos a seguir.

Para nortear este estudo de caso, a questão principal levantada foi **Q1: “Quais são os resultados ao se utilizar a RNA na previsão de alunos em situação de risco de reprovação em Educação de Computação no contexto Brasileiro?”**

As seguintes proposições foram estabelecidas a fim de serem investigadas. A Proposição 1 (**P1**): “A precisão da RNA alcançou um nível satisfatório.”, Proposição 2 (**P2**): “A acurácia da RNA teve um desempenho satisfatório” e Proposição 3 (**P3**): “A cobertura (*Recall*) atingiu um nível satisfatório”.

3.2.2 Unidade de análise, Coleta de Dados e Análise dos dados

A unidade de análise do estudo é a turma de 2019.2 da disciplina de Interface Humano-Computador do Bacharelado em Ciência da Computação da Universidade Federal de Jataí, localizada no sudoeste goiano.

A coleta dos dados terá quatro fontes: as respostas dos alunos no Kahoot! de 2018.2 (F1), o resultado final do processo de avaliação somativa dos alunos da turma de 2018.2 (F2), as respostas ao Kahoot! de 2019.2 (F3) e o resultado parcial da avaliação formativa dos alunos da turma de 2019.2 (F4). As duas turmas são da disciplina de Interface Humano-Computador.

Os dados coletados consistem em dois conjuntos: as respostas dadas pelos alunos no decorrer das aulas, às perguntas elaboradas pelo professor que ministra a disciplina, através da ferramenta de tecnologia educacional, “Kahoot!”, que foi descrita na seção [1.4.1](#) e os resultados acadêmicos obtidos - aprovado ou reprovado - por esses alunos.

3.2.3 Análise dos Dados

Para verificar se há ligação entre os dados coletados e a proposição estabelecida, tomaremos como métrica para “previsão satisfatória”, os resultados de **precisão e acurácia** obtidos por trabalhos correlatos. Os dados coletados servirão como suporte para a proposição através da métrica adotada. Para melhor compreensão, os conceitos Acurácia e Precisão são importantes de serem explicados.

3.2.3.1 Precisão e Acurácia

Precisão se define como a proximidade entre os valores obtidos pela repetição do processo de mensuração. Quanto menor é a diferença destes valores, melhor é a precisão.



Figura 3 – Diferença entre Acurácia e Precisão

Acurácia se define como a proximidade da medida em relação ao verdadeiro valor, um valor definido, que se deseja obter. Quanto mais próximo do valor real, melhor é a acurácia. A [Figura 3](#) esclarece isso de maneira bem didática.

3.3 Classificação da pesquisa

A classificação desse projeto de pesquisa pode ser feito em termos de gêneros da mesma. Estes gêneros dizem respeito à natureza, os objetivos, os procedimentos, o objeto e à forma de abordagem desta.

3.3.1 Gêneros de Pesquisa

3.3.1.1 Quanto à natureza

Empírica, pois a pesquisa dedica-se recolher dados diretamente da realidade do objeto de estudo, mensurar a realidade, formular observações e propor transformações do mesmo enquanto objeto de investigação, mas não intervem de forma concreta no ambiente durante o trajeto da pesquisa.

3.3.1.2 Quanto aos objetivos

Pesquisa exploratória: Apesar de haverem pesquisas em relação à métodos para a predição de desempenho acadêmico, há a necessidade de se relatar casos no Brasil, que ocorram experimentos da aplicação desses métodos no processo de avaliação de aprendizagem, identificando alunos em situação de risco.

3.3.1.3 Quanto aos procedimentos

Pesquisa de Campo: Todos os procedimentos que serão usados nesta pesquisa serão derivados de coletas de dados realizadas em fontes diretas. Desta forma, esta pesquisa

quantos aos procedimentos é de campo, pois baseia-se em dados coletados no local da ocorrência dos fatos.

3.3.1.4 Quanto ao objeto

Pesquisa de campo: O principal objeto desta pesquisa é justamente a identificação prévia de alunos em risco de reprovação e o uso de Redes Neurais Artificiais como método preditivo. O conceito sobre o objeto, o problema relacionado ao mesmo, assim como a justificativa, são oriundos de uma coleta de dados realizada em local, tornando esta pesquisa de campo quanto aos objetos.

3.3.1.5 Quanto à forma de abordagem

Pesquisa quantitativa: Serão coletadas as respostas dadas pelos alunos, analisando os dados gerados, com o modelo de Rede Neural criado, e produzindo, assim, uma saída classificada.

4 Cronograma

O cronograma tem por objetivo prever as ações distribuídas de acordo com o tempo previsto de pesquisa. Alinhado com os objetivos específicos e com a metodologia, o cronograma descreva em quais prazos os objetivos específicos serão feitos.

A [Tabela 3](#) apresenta o cronograma de execução da pesquisa.

Tabela 3 – Cronograma de Atividades

<i>Atividades</i>	<i>Mês</i>	<i>Ano</i>
Revisão literária	Agosto	2019
Projeto e implementação da Rede Neural	Agosto e Setembro	2019
Coleta de Dados - IHC/2019.2	Agosto e Setembro	2019
Treinamento da Rede Neural	Outubro	2019
Análise dos resultados obtidos	Novembro e Dezembro	2019

Referências

- ABIDIN, H. Z.; ZAMAN, F. K. Students' perceptions on game-based classroom response system in a computer programming course. In: IEEE. *2017 IEEE 9th International Conference on Engineering Education (ICEED)*. [S.l.], 2017. p. 254–259. Citado na página 14.
- ABOUT Kahoot! 2019. <<https://kahoot.com/company/>>. Accessed: 2019-06-15. Citado na página 13.
- AHADI, A. Early identification of novice programmers' challenges in coding using machine learning techniques. In: ACM. *Proceedings of the 2016 ACM Conference on International Computing Education Research*. [S.l.], 2016. p. 263–264. Citado 5 vezes nas páginas 8, 19, 20, 21 e 22.
- BELLMAN, R. *An introduction to artificial intelligence: Can computers think?* [S.l.]: Thomson Course Technology, 1978. Citado na página 11.
- BLANDO, A. Dificuldades acadêmicas que interferem na aprendizagem de estudantes universitários de engenharias e de ciências exatas: um estudo fundamentado na epistemologia genética. 2015. Citado na página 7.
- BLOOM, B. S. et al. *Manual de avaliação formativa e somativa do aprendizado escolar*. [S.l.: s.n.], 1983. Citado na página 10.
- BRITO, D. M. et al. Predição de desempenho de alunos do primeiro período baseado nas notas de ingresso utilizando métodos de aprendizagem de máquina. v. 25, n. 1, p. 882, 2014. Citado 3 vezes nas páginas 20, 21 e 22.
- CASTRO-WUNSCH, K.; AHADI, A.; PETERSEN, A. Evaluating Neural Networks as a Method for Identifying Students in Need of Assistance. *ACM Technical Symposium on Computer Science Education*, p. 111–116, 2017. Disponível em: <<http://dl.acm.org/citation.cfm?doid=3017680.3017792>>. Citado 4 vezes nas páginas 19, 20, 21 e 22.
- CORREIA, M.; SANTOS, R. Game-based learning: The use of kahoot in teacher education. In: IEEE. *2017 International Symposium on Computers in Education (SIIE)*. [S.l.], 2017. p. 1–4. Citado na página 14.
- DATRINO, R. C.; DATRINO, I. F.; MEIRELES, P. H. Avaliação como processo de ensino-aprendizagem. *Revista de Educação*, v. 13, n. 15, 2015. Citado na página 10.
- DINIZ, L. M. F.; FERREIRA, F. Kahoot!: um relato de experiência no contexto acadêmico. In: SBC. *26º Workshop sobre Educação em Computação (WEI 2018)*. [S.l.], 2018. v. 26, n. 1/2018. Citado na página 14.
- DOMINGOS, A.; NEVES, I.; GALHARDO, L. *Uma forma de estruturar o ensino e a aprendizagem*. Livros Horizonte, 1981. (Biblioteca do educador profissional). ISBN 9789722401067. Disponível em: <<https://books.google.com.br/books?id=P3yPGAAACAAJ>>. Citado na página 9.

- ESTEY, A.; KEUNING, H.; COADY, Y. Automatically classifying students in need of support by detecting changes in programming behaviour. In: ACM. *Proceedings of the 2017 ACM SIGCSE Technical Symposium on Computer Science Education*. [S.l.], 2017. p. 189–194. Citado na página 8.
- FINCHER, S.; PETRE, M. Mapping the territory. In: *Computer Science Education Research*. [S.l.]: Taylor & Francis, 2005. p. 11–18. Citado 2 vezes nas páginas 7 e 9.
- GIBBS, N. E.; TUCKER, A. B. A model curriculum for a liberal arts degree in computer science. *Communications of the ACM*, ACM, v. 29, n. 3, p. 202–210, 1986. Citado na página 9.
- GOTARDO, R.; CEREDA, P. R. M.; JUNIOR, E. R. H. Predição do desempenho do aluno usando sistemas de recomendação e acoplamento de classificadores. In: *Brazilian Symposium on Computers in Education (Simpósio Brasileiro de Informática na Educação-SBIE)*. [S.l.: s.n.], 2013. v. 24, n. 1, p. 657. Citado 4 vezes nas páginas 19, 20, 21 e 22.
- HAYDT, R. C. Avaliação do processo ensino-aprendizagem. 6º edição—são paulo. Editora Ática, 2007. Citado 2 vezes nas páginas 10 e 11.
- HAYKIN, S. *Redes Neurais Artificiais: Princípios e Práticas*. 2ª edição. [S.l.]: Editora Bookman, Porto Alegre, 900p, 2001. Citado na página 12.
- HOLGUÍN, E. P. et al. Kahoot en docencia: una alternativa practica a los clickers. Universidad Europea de Madrid, 2014. Citado na página 15.
- HOLMBOE, C.; MCIVER, L.; GEORGE, C. E. Research agenda for computer science education. In: *PPIG*. [S.l.: s.n.], 2001. v. 13. Citado 2 vezes nas páginas 7 e 9.
- INEP. *Sinopse Estatística do Censo da Educação Superior 2017*. 2018. Instituto Nacional Estudo e Pesquisas Educacionais Anísio Texeira. Disponível em <<<http://portal.inep.gov.br/basica-censo-escolar-sinopse-sinopse>>>. Acesso em 22 de novembro de 2018. Citado na página 7.
- JORBA, J.; SANMARTI, N. A função pedagógica da avaliação. *Avaliação como apoio à aprendizagem*. Porto Alegre: Artmed, p. 23–45, 2003. Citado na página 11.
- KITCHENHAM, B. Procedures for performing systematic reviews. *Keele, UK, Keele University*, v. 33, n. 2004, p. 1–26, 2004. Citado 2 vezes nas páginas 16 e 18.
- KRAEMER, M. E. P. Avaliação da aprendizagem como construção do saber. INPEAU, 2005. Citado 2 vezes nas páginas 10 e 11.
- LIAO, S. N. et al. Lightweight, early identification of at-risk cs1 students. In: ACM. *Proceedings of the 2016 ACM Conference on International Computing Education Research*. [S.l.], 2016. p. 123–131. Citado na página 7.
- LIBÂNEO, J. C. Didática—são paulo. Editora Cortês, Coleção Magistério, v. 20, 1994. Citado 2 vezes nas páginas 9 e 10.
- LIPP, G. *Kahoot! as Formative Assessment*. 2015. <<https://learninginnovation.duke.edu/blog/2015/07/kahoot-as-formative-assessment>>. Accessed: 2019-06-15. Citado na página 14.

- LOT, M.; SALLEH, S. M. Game-based learning as a platform for formative assessment in principles of account. *International Information Institute (Tokyo). Information*, International Information Institute, v. 19, n. 9B, p. 3971, 2016. Citado na página 13.
- MARTINS, L. C.; LOPES, D. A.; RAABE, A. Um assistente de predição de evasão aplicado a uma disciplina introdutória do curso de ciência da computação. In: *Brazilian Symposium on Computers in Education (Simpósio Brasileiro de Informática na Educação-SBIE)*. [S.l.: s.n.], 2012. v. 23, n. 1. Citado na página 7.
- MASETTO, M. T. Didática: a aula como centro. 1994. Citado na página 10.
- MONARD, M. C.; BARANAUSKAS, J. A. Sistemas inteligentes: fundamentos e aplicações, chapter conceitos sobre aprendizado de máquina. *Rezende (2003)*, v. 15, p. 89–114, 2003. Citado na página 12.
- MONSALVE, E. S. *Aprendizagem Baseada em Jogos*. Tese (Doutorado) — PUC-Rio, 2014. Citado na página 13.
- MONSALVE, E. S.; WERNECK, V. M. B.; LEITE, J. C. S. do P. Teaching software engineering with simules-w. In: IEEE. *2011 24th IEEE-CS Conference on Software Engineering Education and Training (CSEET)*. [S.l.], 2011. p. 31–40. Citado na página 13.
- OLIVEIRA, J. B. A. e; CHADWICK, C. *Aprender e ensinar*. [S.l.]: Instituto Alfa Educativca, 2004. Citado na página 11.
- PALMEIRA, L. B.; SANTOS, M. P. Evasão no bacharelado em ciência da computação da universidade de brasília: análise e mineração de dados. 2015. Citado na página 7.
- PERRENOUD, P. A avaliação no princípio da excelência e do êxito escolares. *Avaliação: da excelência à regulação das aprendizagens-entre duas lógicas*, Artes Médicas Sul Porto Alegre, 1999. Citado na página 11.
- PETRI, G. et al. Um quiz game para a revisão de conhecimentos em gerenciamento de projetos. In: *Brazilian Symposium on Computers in Education (Simpósio Brasileiro de Informática na Educação-SBIE)*. [S.l.: s.n.], 2016. v. 27, n. 1, p. 320. Citado na página 14.
- PORTER, L.; ZINGARO, D. Importance of early performance in cs1: two conflicting assessment stories. In: ACM. *Proceedings of the 45th ACM technical symposium on Computer science education*. [S.l.], 2014. p. 295–300. Citado na página 8.
- QUILLE, K.; BERGIN, S. Programming: predicting student success early in cs1. a re-validation and replication study. In: ACM. *Proceedings of the 23rd Annual ACM Conference on Innovation and Technology in Computer Science Education*. [S.l.], 2018. p. 15–20. Citado na página 8.
- REIS, R. et al. Experiência de uso de jogos educacionais digitais individuais em contextos de colaboração. In: *Anais do Workshop de Informática na Escola*. [S.l.: s.n.], 2016. v. 22, n. 1, p. 485. Citado na página 13.
- RODRIGUES, R. L.; MEDEIROS, F. P. de; GOMES, A. S. Modelo de regressão linear aplicado à previsão de desempenho de estudantes em ambiente de aprendizagem. In: *Brazilian Symposium on Computers in Education (Simpósio Brasileiro de Informática na Educação-SBIE)*. [S.l.: s.n.], 2013. v. 24, n. 1, p. 607. Citado na página 8.

RUSSELL, S.; NORVIG, P. Inteligência artificial, tradução da 2a. Edição, Editora Campus, Brazil, 2004. Citado 2 vezes nas páginas 11 e 12.

SAGE, A. P. *Concise Encyclopedia of Information Processing in Systems & [and] Organizations*. [S.l.]: Pergamon Press Oxford, UK, 1990. Citado na página 12.

SILVA, J. M. C. d. et al. Alunos em risco: como identificá-los por meio de um ambiente virtual de aprendizagem? 2014. Citado 2 vezes nas páginas 7 e 10.

SOUZA, M. R. A. et al. Games for learning: Bridging game-related education methods to software engineering knowledge areas. In: *Proceedings of the 39th International Conference on Software Engineering: Software Engineering and Education Track*. Piscataway, NJ, USA: IEEE Press, 2017. (ICSE-SEET '17), p. 170–179. ISBN 978-1-5386-2671-9. Disponível em: <<https://doi.org/10.1109/ICSE-SEET.2017.17>>. Citado na página 13.

TANG, S.; HANNEGHAN, M.; RHALIBI, A. E. Introduction to games-based learning. In: *Games-based learning advancements for multi-sensory human computer interfaces: Techniques and effective practices*. [S.l.]: IGI Global, 2009. p. 1–17. Citado na página 13.

WANGENHEIM, C. G. V.; SHULL, F. To game or not to game? *IEEE software*, IEEE, v. 26, n. 2, p. 92–94, 2009. Citado na página 13.

WEISZFLOG, W. *Michaelis: moderno dicionário da língua portuguesa*. [S.l.]: Melhoramentos, 1999. Citado na página 9.

YIN, R. K. Estudo de caso: Planejamento e métodos. *Trad. Daniel Grassi*, v. 2, 2001. Citado 2 vezes nas páginas 26 e 27.